

ARQUIVO, REGISTRO E CHAVE - Um arquivo é uma coleção lógica de registros sequenciais. Eles são mapeados em blocos de disco que possuem um tamanho fixo determinado pelas propriedades físicas do disco e pelo sistema operacional. Os registros podem ter tamanhos fixos ou variáveis e são compostos por campos que representam atributos da entidade representada. Uma chave é uma sequência de um ou mais campos. A chave primária é uma chave que apresenta valores distintos para cada registro do arquivo. A chave secundária difere da primária por permitir duplicações e, desta forma, normalmente identifica um conjunto de registros.

REPRESENTAÇÃO DE REGISTROS - Para registros de tamanho fixo, colocamos um atrás do outro. Na exclusão, usa-se a ideia de lista livre, com o endereço inicial no cabeçalho, p/ preencher os espaços excluídos c/ novos registros. Para registros de tamanho variável, podemos colocar um caracter de fim de registro, porém, por problemas de reutilizar um espaço ocupado por um registro apagado, utiliza-se a estrutura slotted-page (FIGURA 1), onde os registros são organizados dentro de um bloco, de forma contínua, a partir do fim do bloco. Outra maneira é preencher com espaços em branco os registros p/ que se tornem fixos. Isso é útil quando a maioria dos registros tem um tamanho próximo do tamanho máximo. Por fim, outra maneira é criar um campo de endereço em cada registro que aponte p/ uma área de overflow quando necessário.

ORGANIZAÇÃO DE ARQUIVOS - Dado um conjunto de registros, temos 4 principais maneiras de organizá-los dentro de um arquivo: sequencial, sequencial-indexado, indexado e acesso direto. **ORGANIZAÇÃO SEQUENCIAL** - A ordem lógica e física dos registros é a mesma e eles estão ordenados por uma chave primária, única, e crescente. São úteis p/ classificação e acesso de um grande número de dados e processamento serial. Consulta-se por pesquisa exaustiva ou pesquisa binária, esta quando a chave de acesso = chave de ordenação. A inserção pode ser feita na posição adequada movendo um grande número de registros ou em arquivo auxiliar. A exclusão pode ser física ou lógica. A reorganização elimina registros excluídos logicamente e intercala os arquivos auxiliares.

ORGANIZAÇÃO SEQUENCIAL-INDEXADA - Quando o volume de acesso torna-se muito grande, temos associado ao arquivo sequencial de dados um arquivo de índice, que é formado por duplas: chave de acesso e endereço no arquivo de dados. O arquivo de índice deve estar fisicamente ordenado. A inclusão de registros deve ser feita na área de extensão, que pode ser implementada com um campo de elo em cada registro ou um campo de elo a cada bloco (alternativa inviável se existirem índices secundários). A exclusão é realizada logicamente. A reorganização do arquivo é necessária quando a área de extensão ficar muito grande, além de reestruturar o arquivo de índices e eliminar registros excluídos logicamente. Esta organização está representada na FIGURA 2.

ORGANIZAÇÃO INDEXADO - Quando a necessidade de acessos seriais é reduzida, podemos acessar o arquivo apenas por índices, não sendo necessário manter a sequencialidade física dos registros no arquivo de dados. Dessa forma, a área de extensão é dispensada, porém, os índices devem estar atualizados sempre. Podem existir tantos índices quantas forem as chaves de acesso do arquivo de dados. O índice primário de um arquivo indexado é chamado de índice exaustivo, pois possui uma entrada p/ cada registro. Os índices secundários são chamados de índices seletivos, p/ cada entrada se relaciona c/ um subconjunto do arquivo de dados. A exclusão pode ser física ou lógica e a alteração de um registro pode implicar na alteração dos índices. A reorganização só é necessária quando os registros excluídos logicamente não são aproveitados pelo algoritmo de inclusão. Esta organização está representada na FIGURA 3.

ORGANIZAÇÃO DE ACESSO DIRETO - Há uma relação definida entre o valor da chave primária de um registro e seu endereço. Há dois métodos: no endereçamento direto, por exemplo se o valor da chave varia de 0 a 4000, deve-se gravar 4000 registros, mesmo que alguns em branco, já que cada registro possui um endereço físico pre-definido. É vantajoso quando o número de valores de chave possível é próximo do número real de valores da chave; no endereçamento indireto, todo o registro lógico é mapeado p/ uma área de armazenamento através de uma função hash. Essas áreas podem conter um ou mais registros. O valor gerado pela função hash é usado em um acesso por endereçamento direto. Os seguintes fatores devem ser considerados na definição de uma função hash: tamanho da área (área pequena gera muitas colisões e grande desperdiza espaço), fator de carga (proporção entre o núm. de registros existentes no arquivo e o núm. de registros disponíveis no arquivo) e o tipo de transformação. A consulta de registros é realizada pela geração do endereço pela função hash e pelo método de tratamento de colisões. A exclusão lógica é melhor e a reorganização pode ser feita para eliminá-las.

ORDENAÇÃO DE ARQUIVOS: PARTICIONAMENTO - Métodos de geração de partições: classificação interna: lê M registros p/ a memória, ordena-os e grava em uma partição; seleção com substituição: lê M registros p/ a memória; seleciona destes o menor e grava na partição; substitui, no array de mem pelo próximo registro de entrada; caso a chave deste último seja menor do que a chave recém-gravada, considerá-lo congelado; enquanto existirem posições não congeladas, repetir, caso contrário, uma nova partição será aberta e o array de memória começará c/ os registros congelados. O tamanho médio das partições é $2 \cdot M$; seleção natural: lê M registros da memória, seleciona o menor p/ a partição, substitui pelo próximo da entrada e caso ele seja menor do que o recém-gravado, colocar no reservatório (de tamanho M e na mem. secundária) e substituir de novo pelo próximo. Quando o reservatório encher, pegar os valores restantes na memória e jogar na partição, colocar o reservatório no array de memória, esvaziá-lo e abrir nova partição. **ORDENAÇÃO DE ARQUIVOS: INTERCALAÇÃO** - Todas as partições são abertas e o primeiro registro de cada um é carregado na memória, o menor é gravado na saída e substituído pelo seu sucessor. Usa-se Arvore Binária.

de vencedores p/ diminuir as operações de busca (FIGURA 4). Quando o número de arg. é maior do que o suportado, mais fases são necessárias e usa-se a intercalação ótima (FIGURA 5). **ÍNDICES: LISTAS** - útil p/ chaves secundárias, já que uma chave pode retornar muitos valores (registros). **ÍNDICES: Mapeamento de Bits** - útil quando a chave secundária possui um conjunto bem definido de valores. **ÍNDICES: ARVORE B** - útil p/ chave primária. O número mínimo de chaves em um nó é a ordem (D), e o máximo é 2D. O número mínimo de filhos é D+1 e o máximo é 2D+1. A raíz é exceção.

FIGURA 5 - inter. ótima c/ 3 arg. de 100 registros cada.

	ENTRADA			SAÍDA
FASE	ARG 1	ARG 2	ARG 3	Nº DE LEITURAS
1	1:100	2:100	6:200	200
2	3:100	4:100	7:200	200
3	5:100	6:200	8:300	300
4	7:200	8:300	9:500	500
			TOTAL →	1200

$$\text{nº de passos} = \frac{1200}{500} = 2,4$$

FIGURA 3 - org. indexado

nome	end
Ângela	3
Antônio	6
César	4
Gizele	5
Helena	2
Ivan	1

Índice chave sec.

num	end
1050	6
1075	3
1350	4
1900	5
2000	2
2400	1

Índice chave prim.

O tamanho deve ser um núm. primo não próximo de uma potência de 2.
 $\text{REHASH} = (\text{hash} + 1) \% \text{tamanho}$
 FUN. HASH ⇒ resto da divisão inteira da chave pelo tamanho do vetor.

FIGURA 4 - árvore de vencedores




FIGURA 1 - slotted-page




FIGURA 2 - org. seq.-indexado

num	end
1100	1
*	3

Índice secund.

num	end
1050	1
1100	3
1350	5
*	7

Índice primário

num	nome	idade
2400	Ivan	28
2000	Helena	22
1075	Ângela	22
1350	César	24
1900	Gizele	27
1050	Antônio	21

arg. de dados

num	nome	idade
1000	Ademar	23
1050	Valcir	27
1075	Pedro	21
1100	Valdir	19
1300	Edoardo	33
1350	Helena	25
1375	Henrique	34

arquivo de dados

: extensão

pode conter um campo de exclusão lógica.

pode-se adicionar o campo de elo e exclusão lógica.